Felipe DIPP ALCON

PROJET INGÉNIEUR CITOYEN

EcoPrompt

Analyse et sensibilisation à l'empreinte environnementale de l'intelligence artificielle

Le projet Ingénieur Citoyen a pour objectif de concrétiser une réponse à un besoin en lien avec une problématique écologique ou sociale.

Dans le cadre de ce projet, une application Python nommée **EcoPrompt** a été conçue, développée et testée. Elle permet d'**estimer**, de **visualiser** et de **signaler** l'empreinte environnementale (énergie, émissions de CO_2e, eau) associée à l'utilisation d'outils d'intelligence artificielle générative.

Le projet comprend quatre livrables :

- le présent rapport académique ;
- le code source Python complet (Streamlit, Pandas, Plotly, SQLite, Pytest) ;
- un dépôt GitHub prêt à publier (README, dépendances, tests, licence) ;
- un guide de démonstration pour la soutenance orale.

Auteur : Felipe DIPP ALCON — INSA Toulouse, cycle préparatoire intégré.

Dépôt du code : https://github.com/<identifiant>/EcoPrompt *(à compléter après publication)*.

Règle de rigueur appliquée dans tout le document. Chaque chiffre est accompagné de sa source, de sa date, de son unité et de sa nature : **mesuré** (télémétrie ou mesure instrumentée publiée), **estimé** (modèle ou calcul), **statistique** (donnée officielle agrégée) ou **convention** (choix pédagogique propre à EcoPrompt). Les résultats produits par EcoPrompt sont toujours des **estimations**.

SOMMAIRE

1. Introduction et contexte environnemental
2. Présentation du problème sociétal
3. Problématique
4. Objectifs du projet
5. Présentation de la solution EcoPrompt
6. Fonctionnement technique de l'application
7. Méthodologie et architecture informatique
8. Travail pratique et développement Python
9. Calcul estimatif des émissions de CO_2
10. Estimation de la consommation énergétique
11. Estimation de la consommation d'eau
12. Système d'alertes environnementales
13. Résultats attendus et validation expérimentale
14. Impact social et sensibilisation citoyenne
15. Limites scientifiques et techniques
16. Perspectives d'amélioration
17. Conclusion
18. Bibliographie et sources scientifiques

Liste des figures

Fig. 1 — Schéma de fonctionnement d'EcoPrompt

Fig. 2 — Architecture logicielle en couches

Fig. 3 — Formulaire de simulation

Fig. 4 — Résultats, alerte et décomposition

Fig. 5 — Chaîne de calcul de l'énergie, du CO_2e et de l'eau

Fig. 6 — Énergie estimée par requête selon le modèle et la longueur de réponse

Fig. 7 — Tableau de bord environnemental

Fig. 8 — Comparaison de scénarios

Fig. 9 — Énergie annuelle estimée de quatre scénarios

Fig. 10 — Page « Mon impact citoyen »

Fig. 11 — Page « Méthodologie et sources »

1. INTRODUCTION ET CONTEXTE ENVIRONNEMENTAL

L'intelligence artificielle générative (agents conversationnels, génération de texte, de code ou d'images) s'est diffusée très rapidement dans les usages étudiants, professionnels et domestiques. Derrière chaque requête se trouve pourtant une infrastructure physique : des centres de données équipés d'accélérateurs (GPU, TPU), alimentés en électricité et refroidis, souvent avec de l'eau.

À l'échelle mondiale, l'Agence internationale de l'énergie estime que les centres de données ont consommé environ **415 TWh en 2024**, soit près de **1,5 %** de l'électricité mondiale, et projette **945 TWh en 2030** dans son scénario de référence, l'IA étant présentée comme le principal moteur de cette hausse [8]. Les impacts environnementaux de l'IA se mesurent principalement selon trois grandeurs : l'**énergie** consommée, les **émissions de gaz à effet de serre** qui en résultent (selon le mix électrique) et la **consommation d'eau** (refroidissement sur site et production de l'électricité).

Indicateur	Valeur	Unité	Date	Nature	Source
Électricité des centres de données (monde)	415 (≈ 1,5 %)	TWh/an	2024	estimé	IEA 2025 [8]
Projection 2030, scénario de référence	945	TWh/an	2030	estimé	IEA 2025 [8]
Prélèvements d'eau liés à l'IA (projection)	4,2 – 6,6	milliards de m^3	2027	estimé	Li et al. 2025 [4]
Intensité carbone moyenne de l'électricité	473	g CO_2/kWh	2024	statistique	Ember 2025 [9]
Énergie d'une requête texte médiane Gemini	0,24	Wh	mai 2025	mesuré	Google 2025 [2]

Tableau 1 — Chiffres de contexte utilisés dans le rapport.

Ces chiffres globaux sont difficiles à relier à l'usage individuel : un utilisateur ne voit ni le serveur, ni l'électricité, ni l'eau mobilisés par sa requête. C'est ce décalage que le projet EcoPrompt cherche à réduire.

2. PRÉSENTATION DU PROBLÈME SOCIÉTAL

La sobriété numérique est un levier reconnu pour limiter la consommation de ressources. Or l'IA générative présente trois caractéristiques qui rendent cette sobriété difficile :

- **L'invisibilité** : l'interface d'un assistant conversationnel ne donne aucune indication sur le coût énergétique d'une réponse. L'utilisateur perçoit un service immatériel et gratuit.
- **L'effet d'échelle** : une requête isolée représente une énergie faible (de l'ordre du dixième de wattheure selon la mesure publiée par Google [2]), mais les usages se comptent en milliards de requêtes.
- **L'opacité des données** : la plupart des fournisseurs ne publient ni la taille de leurs modèles, ni leur consommation par requête. Les rares valeurs publiées proviennent de périmètres et de méthodes différents [2][7].

Il est par ailleurs courant de reformuler plusieurs fois la même demande, de régénérer une réponse jugée imparfaite, de solliciter un grand modèle pour une tâche simple ou de

demander des réponses très longues. Chacun de ces comportements augmente le nombre de tokens générés, donc l'énergie estimée, sans toujours apporter de valeur supplémentaire.

Un outil doit donc être conçu pour répondre à ce besoin : il doit être **léger** (sans serveur ni service payant), **transparent** sur ses hypothèses, et capable de **traduire un usage déclaré en ordres de grandeur compréhensibles**, accompagnés de conseils concrets.

3. PROBLÉMATIQUE

« Comment sensibiliser les utilisateurs à l'impact environnemental de leurs interactions avec l'intelligence artificielle ? »

Cette question en contient trois : comment **estimer** honnêtement un impact qui n'est pas mesuré directement ; comment le **rendre lisible** sans le dramatiser ni le minimiser ; et comment **orienter les comportements** sans prétendre réduire automatiquement les émissions.

4. OBJECTIFS DU PROJET

Objectif général : développer une application Python fonctionnelle, locale et gratuite qui estime, visualise et signale l'empreinte environnementale d'un usage de l'IA, afin de favoriser une utilisation plus consciente.

N°	Objectif spécifique	Indicateur de réussite
O1	Estimer l'énergie (Wh), le CO_2e (g) et l'eau (L) à partir d'un usage déclaré	Formules publiées, implémentées et testées
O2	Rendre chaque hypothèse traçable et modifiable	100 % des paramètres reliés à une source (test automatique)
O3	Distinguer mesuré, estimé et convention	Étiquetage visible dans l'application
O4	Alerter avec des niveaux vert / orange / rouge et des conseils	Seuils configurables, messages contextualisés
O5	Suivre l'évolution et comparer des scénarios	Historique SQLite, graphiques interactifs
O6	Sensibiliser à l'échelle collective	Page « Mon impact citoyen »
O7	Garantir la reproductibilité	Dépôt GitHub, dépendances documentées, tests

Tableau 2 — Objectifs spécifiques et critères de réussite.

5. PRÉSENTATION DE LA SOLUTION ECOPROMPT

EcoPrompt (« Comprendre son impact, utiliser l'IA autrement ») est une application web locale développée avec Streamlit. L'utilisateur décrit son usage (nombre de requêtes, fréquence, catégorie de modèle, tokens d'entrée et de sortie) ; l'application calcule une estimation, l'affiche sous forme d'indicateurs et de graphiques, attribue un niveau d'alerte et propose des conseils. Les simulations peuvent être enregistrées pour suivre leur évolution.

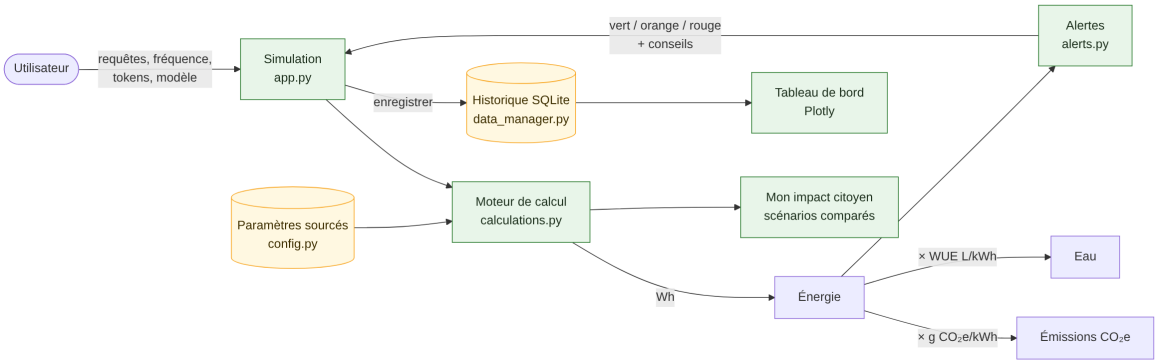


Fig. 1 — Schéma de fonctionnement d'EcoPrompt.

Page	Rôle
Simulation	Saisie de l'usage, résultats par requête / semaine / an, alerte
Tableau de bord	Indicateurs cumulés, évolution temporelle, alertes, export CSV
Comparer des scénarios	Scénarios sobre / courant / intensif / images, courbes
Mon impact citoyen	Effet de nouvelles habitudes, à l'échelle d'un groupe
Méthodologie et sources	Formules, paramètres, entraînement, bibliographie
Paramètres	PUE, intensité carbone, eau, seuils, hypothèse avancée

Tableau 3 — Les six pages de l'application.

EcoPrompt fonctionne **sans connexion à une API d'IA** : il ne mesure pas les requêtes réelles, il estime l'impact d'un usage déclaré. Ce choix garantit la gratuité, la confidentialité (aucune donnée ne quitte l'ordinateur) et la reproductibilité.

6. FONCTIONNEMENT TECHNIQUE DE L'APPLICATION

Le parcours utilisateur se déroule en quatre étapes : (1) saisie du scénario dans un formulaire ; (2) validation des entrées (valeurs négatives, non numériques ou incohérentes refusées avec un message en français) ; (3) calcul par le moteur *calculations.py* ; (4) affichage des résultats, de l'alerte et, sur demande, enregistrement dans l'historique.

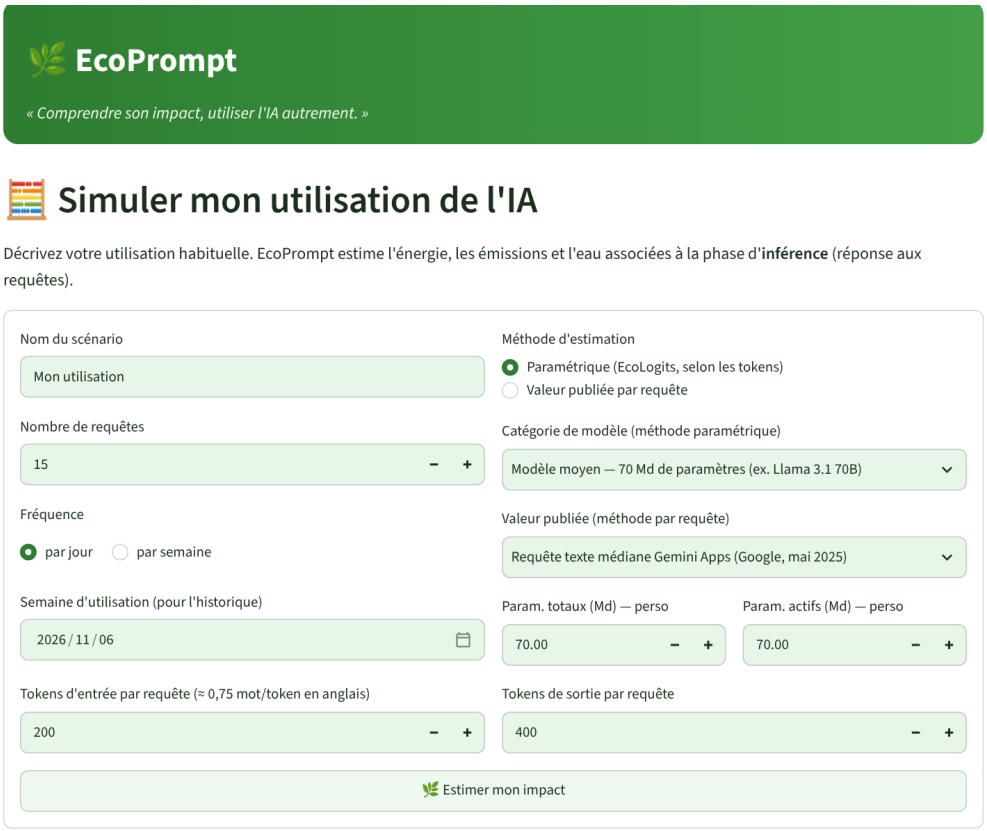


Fig. 3 — Formulaire de simulation (capture de l'application, paramètres par défaut).

Deux méthodes d'estimation sont proposées. La **méthode paramétrique** (par défaut) dépend du nombre de tokens de sortie et de la taille du modèle (section 10). La **méthode par valeur publiée** multiplie le nombre de requêtes par une énergie par requête issue de la littérature (Google 2025 ; Luccioni et al. 2024). Les paramètres environnementaux (PUE, intensité carbone, facteurs hydriques) sont choisis dans la page « Paramètres » parmi des valeurs sourcées, ou saisis librement.

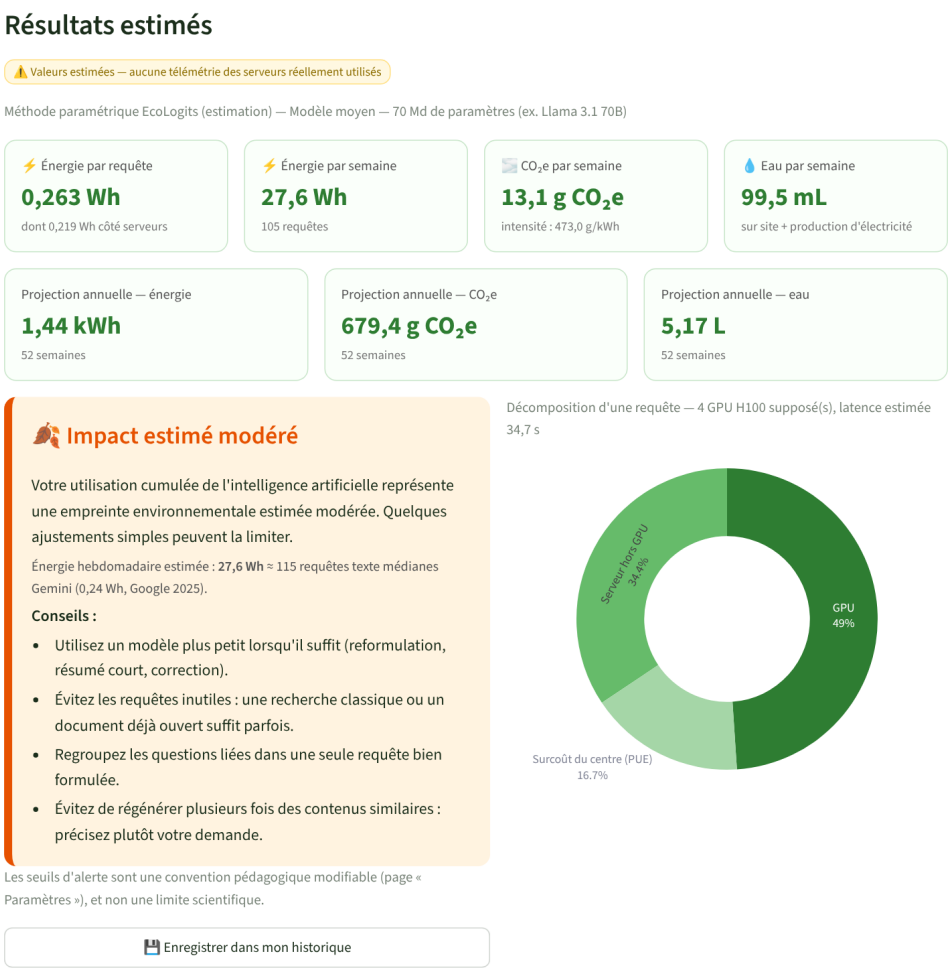


Fig. 4 — Résultats estimés, alerte et décomposition d'une requête (15 requêtes/jour, modèle 70 Md, 400 tokens).

7. MÉTHODOLOGIE ET ARCHITECTURE INFORMATIQUE

Le projet suit une démarche itérative : (1) recherche bibliographique et sélection des sources ; (2) choix d'une méthode de calcul publiée et réutilisable ; (3) implémentation de la logique métier indépendante de l'interface ; (4) écriture des tests unitaires ; (5) développement de l'interface ; (6) vérification par comparaison avec des valeurs publiées (section 13).

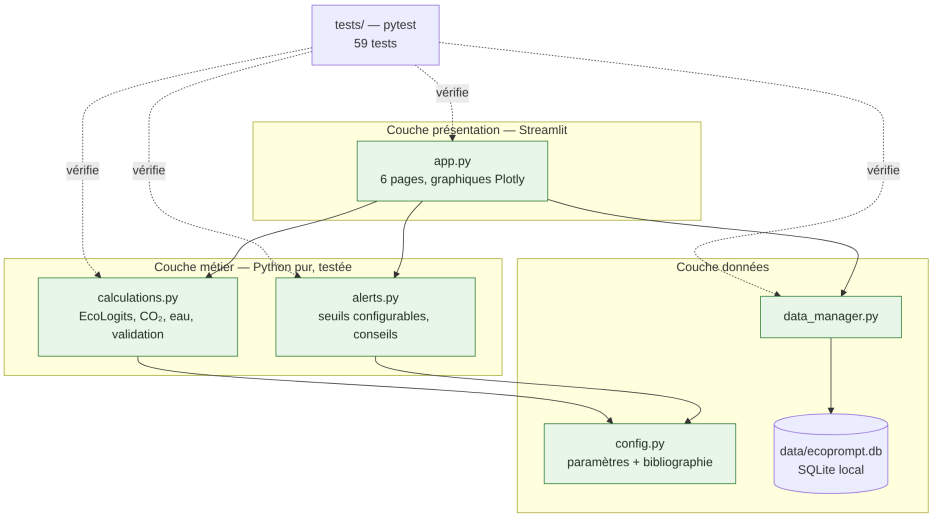


Fig. 2 — Architecture logicielle en couches.

Fichier	Contenu	Lignes
app.py	Interface Streamlit, 6 pages, graphiques Plotly, style vert et blanc	≈ 670
calculations.py	Formules EcoLogits, CO_2e, eau, scénarios, validation	≈ 330
alerts.py	Classement vert / orange / rouge, messages, conseils ciblés	≈ 110
data_manager.py	Historique SQLite : ajout, lecture, suppression, export CSV	≈ 120
config.py	Paramètres, profils de modèles, bibliographie structurée	≈ 330
tests/	59 tests pytest : formules, alertes, base de données, interface	≈ 310

Tableau 4 — Organisation du code source.

Choix techniques justifiés. Streamlit permet une interface web en Python pur, sans compétences front-end. SQLite, inclus dans la bibliothèque standard, stocke l'historique dans un fichier local sans serveur. Plotly produit des graphiques interactifs (survol, zoom). La séparation stricte entre interface et calcul rend les formules testables indépendamment de l'affichage.

8. TRAVAIL PRATIQUE ET DÉVELOPPEMENT PYTHON

Le cœur du programme est la fonction qui estime l'énergie d'une requête. Elle transcrit directement les formules publiées par EcoLogits [1] et renvoie une décomposition par poste, ce qui permet de l'afficher et de la tester :

```
def ecologits_request_energy(output_tokens, active_params_b, total_params_b, pue):
    n_gpu = required_gpus(total_params_b)                  # GPU H100 de 80 Go
    e_gpu = output_tokens * gpu_energy_per_token_wh(active_params_b) * n_gpu
    latency_s = output_tokens * latency_per_token_s(active_params_b)
    e_server_other = (latency_s / 3600) * 1.2 * 1000 * (n_gpu / 8) / 64   # Wh
    e_server = e_gpu + e_server_other                     # énergie informatique
    return {..., "it_wh": e_server, "total_wh": e_server * pue}
```

Validation des entrées. Toute valeur est contrôlée avant calcul : type numérique, valeur finie, positivité, bornes maximales, cohérence (paramètres actifs ≤ paramètres totaux ; seuil orange > seuil vert). Les erreurs lèvent une exception *ValidationError* affichée en français dans l'interface. La base SQLite comporte en plus des contraintes *CHECK* qui refusent les valeurs négatives.

Tests. La suite pytest comporte 59 tests : vérification des formules contre un calcul manuel indépendant, linéarité en nombre de tokens, conversions CO_2e et eau, rejet des entrées invalides, classement des alertes aux bornes, persistance SQLite, et affichage sans erreur des six pages (tests Streamlit *AppTest*). **Résultat de l'exécution : 59 tests réussis, 0 échec** (Python 3.13, novembre 2026).

Galerie — les captures suivantes ont été réalisées sur l'application en fonctionnement local (figures 7, 8, 10 et 11).

9. CALCUL ESTIMATIF DES ÉMISSIONS DE CO_2

Les émissions liées à l'usage sont obtenues en multipliant l'énergie estimée par l'intensité carbone de l'électricité du centre de données :

$$CO_2e\ (g) = E_{requête}\ (kWh) \times I_{réseau}\ (g\ CO_2e/kWh)$$

La localisation des serveurs étant généralement inconnue de l'utilisateur, la **moyenne mondiale** est utilisée par défaut. L'utilisateur peut choisir d'autres valeurs officielles :

Zone	Intensité	Année	Périmètre	Source
Moyenne mondiale	473,0 g CO_2e/kWh	2024	production	Ember 2025 [9]
Union européenne	211,2 g CO_2e/kWh	2024	cycle de vie	OWID/Ember [11]
Chili	259,9 g CO_2e/kWh	2024	cycle de vie	OWID/Ember [11]
France	21,7 g CO_2e/kWh	2024	direct	RTE [10]
France	30,2 g CO_2e/kWh	2024	cycle de vie	RTE [10]
Flotte Google	345,0 g CO_2e/kWh	2024	location-based	Google 2025 [2]
Flotte Google	94,0 g CO_2e/kWh	2024	market-based	Google 2025 [2]

*Tableau 5 — Intensités carbone disponibles dans EcoPrompt (**statistique**).*

Exemple (**estimé**) : pour une requête de 400 tokens sur un modèle de 70 Md de paramètres (énergie estimée 0,263 Wh, section 10), les émissions sont de **0,124 g CO_2e** avec la moyenne mondiale, 0,056 g avec l'Union européenne et 0,0057 g avec le mix français direct. La localisation peut donc faire varier le résultat d'un facteur supérieur à 20.

Ce calcul ne couvre que l'électricité consommée pendant l'utilisation. Les publications les plus complètes ajoutent la fabrication du matériel : Google déclare 0,03 g CO_2e par requête médiane en approche *market-based* [2], et l'analyse de cycle de vie de Mistral AI indique 1,14 g CO_2e pour une réponse de 400 tokens, fabrication incluse [7]. Ces écarts traduisent des périmètres et des modèles différents.

10. ESTIMATION DE LA CONSOMMATION ÉNERGÉTIQUE

10.1 Méthode paramétrique EcoLogits

EcoLogits est une bibliothèque open source publiée dans le *Journal of Open Source Software* [1]. Sa méthodologie modélise l'énergie d'inférence d'un grand modèle de langage à partir de régressions sur des mesures publiques. EcoPrompt en reprend les coefficients sans les modifier (**estimé**) :

Grandeur	Formule (P en milliards de paramètres, B = 64)
Énergie GPU par token de sortie	$f_E(P) = 1{,}17\cdot10^{-6} \cdot e^{-1{,}12\cdot10^{-2}\cdot B} \cdot P_{actifs} + 4{,}05\cdot10^{-5}$ [Wh]
Nombre de GPU	n_{GPU} = plus petite puissance de 2 ≥ 1,2 · P_{total} · 16/8 / 80 (GPU H100, 80 Go)
Latence	$\Delta T = T_{out} \cdot (6{,}78\cdot10^{-4}\cdot P_{actifs} + 3{,}12\cdot10^{-4}\cdot B + 1{,}94\cdot10^{-2})$ [s]
Serveur hors GPU	$E_{srv} = \Delta T \cdot 1{,}2\ kW \cdot (n_{GPU}/8) / B$
Énergie informatique	$E_{serveur} = T_{out} \cdot f_E \cdot n_{GPU} + E_{srv}$
Énergie du centre	$E_{requête} = PUE \cdot E_{serveur}$

Tableau 6 — Formules EcoLogits implémentées dans calculations.py [1].

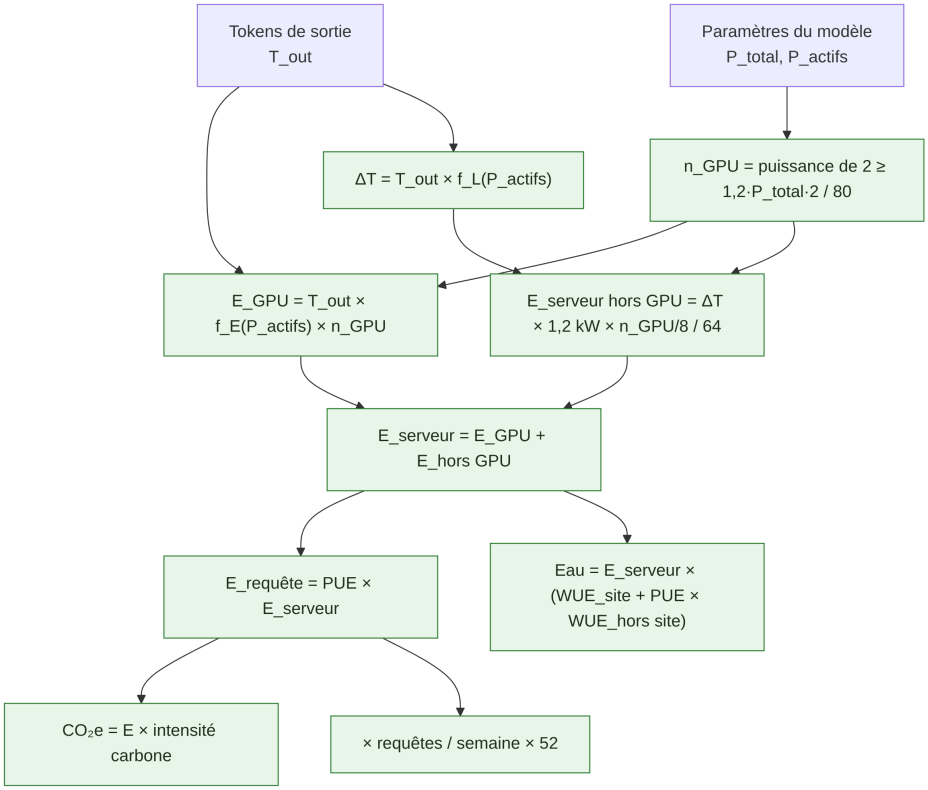


Fig. 5 — Chaîne de calcul de l'énergie, du CO_2e et de l'eau.

Le **PUE** (Power Usage Effectiveness) traduit le surcoût du centre de données (refroidissement, conversion électrique). Valeurs proposées : 1,09 (flotte Google 2024 [2]), 1,16 et 1,20 (valeurs retenues par EcoLogits pour Microsoft en Suède et aux États-Unis [1]). La valeur par défaut est 1,20, la plus prudente des trois.

Les modèles commerciaux (ChatGPT, Gemini, Claude…) ne publient pas leur nombre de paramètres. EcoPrompt propose donc des **profils de taille** correspondant à des modèles

ouverts documentés : Llama 3.1 8B, 70B et 405B [12] et Mixtral 8x22B (141 Md, dont 39 Md actifs) [13]. Le choix d'un profil pour représenter un service commercial est une hypothèse de l'utilisateur.

Profil	GPU	100 tokens	400 tokens	1 000 tokens
Petit modèle — 8 Md de paramètres	1	0,009 Wh	0,036 Wh	0,089 Wh
Modèle moyen — 70 Md de paramètres	4	0,066 Wh	0,263 Wh	0,658 Wh
Mélange d'experts — 141 Md / 39 Md actifs	8	0,101 Wh	0,406 Wh	1,014 Wh
Grand modèle — 405 Md de paramètres	16	0,914 Wh	3,658 Wh	9,145 Wh

*Tableau 7 — Énergie estimée par requête, PUE 1,20 (**estimé**, calcul EcoPrompt).*

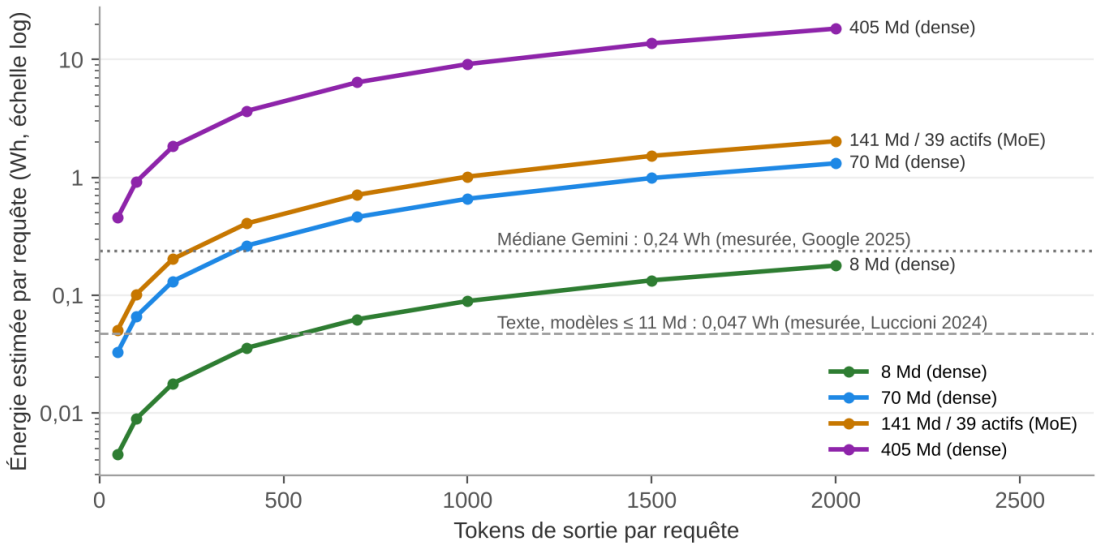


Fig. 6 — Énergie estimée par requête selon le modèle et la longueur de réponse, comparée à deux valeurs mesurées publiées.

Deux constats ressortent : l'énergie est proportionnelle au nombre de tokens générés, et la taille du modèle a un effet très fort (facteur ≈ 100 entre 8 Md et 405 Md). Le modèle MoE, malgré 39 Md de paramètres actifs, est estimé plus énergivore que le modèle dense de 70 Md, car ses 141 Md de paramètres totaux exigent davantage de GPU.

Tokens d'entrée. La méthode EcoLogits ne compte que les tokens de sortie. EcoPrompt les demande quand même à l'utilisateur, les affiche, et propose dans les paramètres un poids optionnel (0 par défaut), signalé comme hypothèse personnelle non sourcée s'il est activé.

10.2 Valeurs publiées par requête

Valeur	Énergie	Nature	Conditions	Source
Requête texte médiane Gemini Apps	0,24 Wh	**mesuré**	Production, mai 2025 ; accélérateurs, CPU/DRAM, machines inactives, PUE 1,09	[2]
Génération de texte (modèles ≤ 11 Md)	0,047 Wh	**mesuré**	0,047 kWh / 1 000 requêtes, écart-type 0,03 ; A100, sans traitement par lots	[3]
Génération d'image	2,907 Wh	**mesuré**	2,907 kWh / 1 000 images, écart-type 3,31	[3]

Tableau 8 — Valeurs par requête utilisables dans la méthode alternative.

10.3 Inférence, entraînement et impacts indirects

EcoPrompt distingue trois niveaux. L'**inférence** (réponse aux requêtes) est seule calculée par défaut. L'**entraînement** est un coût initial très élevé, partagé ensuite entre toutes les requêtes ; comme le nombre total de requêtes servies n'est pas publié, il est présenté séparément, avec un calcul illustratif dont l'hypothèse est choisie par l'utilisateur. Les **impacts indirects** (fabrication du matériel, réseau, terminal, effets rebond) sont hors périmètre et signalés comme tels.

Modèle	Énergie	CO_2e	Eau	Nature	Source
GPT-3 (175 Md)	1 287 MWh	552 t	5,4 millions L (dont 0,7 sur site)	estimé	[5] [4]
BLOOM (176 Md)	433 MWh	24,7 t (50,5 t avec fabrication et inactivité)	—	mesuré + estimé	[6]
Mistral Large 2	—	20 400 t (entraînement + 18 mois d'usage)	281 000 m³	estimé (ACV)	[7]

Tableau 9 — Impacts publiés de l'entraînement (contexte, non additionnés par défaut).

Luccioni et al. (2024) estiment qu'il faut environ **592 millions d'inférences** de BLOOMz-7B pour égaler l'énergie de son entraînement et de son ajustement [3] : pour un modèle très utilisé, l'inférence cumulée peut donc dépasser l'entraînement.

11. ESTIMATION DE LA CONSOMMATION D'EAU

Une méthode documentée existe : Li et al. (2025) [4], reprise par EcoLogits [1], distinguent l'eau évaporée sur site pour le refroidissement (WUE sur site) et l'eau consommée pour produire l'électricité (WUE hors site, ou EWIF) :

$$Eau\ (L) = E_{serveur}\ (kWh) \times [WUE_{site} + PUE \times WUE_{hors\ site}]$$

Profil hydrique	WUE site	WUE hors site	Source
Moyenne Microsoft, États-Unis	0,55 L/kWh	3,142 L/kWh	Li et al. 2025 [4]
Flotte Google 2023–2024 (sur site seulement)	1,15 L/kWh	non inclus	Google 2025 [2]

*Tableau 10 — Facteurs hydriques (**estimé**).*

Exemple (estimé) : la requête de référence (70 Md, 400 tokens) correspond à **0,95 mL** avec le profil Li et al. Appliquée à la valeur médiane Gemini (0,24 Wh) avec le facteur de Google, la même formule donne 0,25 mL, proche des 0,26 mL publiés par Google [2], ce qui vérifie la cohérence de l'implémentation.

Valeur publiée par requête	Eau	Périmètre	Nature	Source
Requête médiane Gemini	0,26 mL	Sur site uniquement	mesuré	[2]
GPT-3, moyenne US, requête moyenne	16,9 mL	Sur site + électricité	estimé	[4]
Le Chat, réponse de 400 tokens	45 mL	ACV (dont fabrication)	estimé	[7]

Tableau 11 — Dispersion des valeurs publiées : un facteur ≈ 170 selon le périmètre.

Cette dispersion justifie l'affichage systématique de la mention « estimé » et la possibilité de désactiver l'estimation de l'eau.

12. SYSTÈME D'ALERTES ENVIRONNEMENTALES

Le niveau d'alerte est déterminé à partir de l'énergie hebdomadaire estimée. Les seuils sont une **convention pédagogique** (**convention**), modifiable dans les paramètres, et non une limite scientifique. Pour rester interprétables, ils sont aussi exprimés en « requêtes médianes Gemini » (0,24 Wh, [2]).

Niveau	Énergie hebdomadaire	≈ requêtes médianes	Message
Vert	< 5 Wh	< 21	Utilisation sous le seuil défini : continuer de façon raisonnée
Orange	5 à 50 Wh	21 à 208	Empreinte estimée modérée : quelques ajustements simples
Rouge	≥ 50 Wh	≥ 208	« Attention : votre utilisation cumulée de l'intelligence artificielle représente une empreinte environnementale estimée. Adoptez une utilisation plus responsable. »

Tableau 12 — Seuils par défaut et messages.

Les conseils sont **ciblés** selon le scénario : génération d'images → réserver aux besoins réels ; grand modèle → utiliser un modèle plus petit lorsqu'il suffit ; réponses ≥ 800 tokens → demander des réponses concises. S'y ajoutent des conseils généraux : éviter les requêtes inutiles, regrouper les questions liées, éviter de régénérer des contenus similaires. Chaque niveau combine couleur, icône et titre textuel, pour ne jamais reposer sur la couleur seule.

13. RÉSULTATS ATTENDUS ET VALIDATION EXPÉRIMENTALE

13.1 Résultats de simulation

Cas	Description	Wh / requête	Wh / semaine	kg CO_2e / an	L d'eau / an	Alerte
Sobre	5 req./jour, 8 Md, 250 tokens	0,022	0,8	0,019	0,15	vert
Courant	15 req./jour, 70 Md, 400 tokens	0,263	27,6	0,679	5,17	orange
Images	10 images/jour (Luccioni et al.)	3,488	244,2	6,006	45,72	rouge
Intensif	40 req./jour, 405 Md, 1 000 tokens	9,145	2 560,5	62,978	479,37	rouge

*Tableau 13 — Résultats **estimé**s (PUE 1,20 ; 473 g CO_2e/kWh ; profil hydrique Li et al.).*

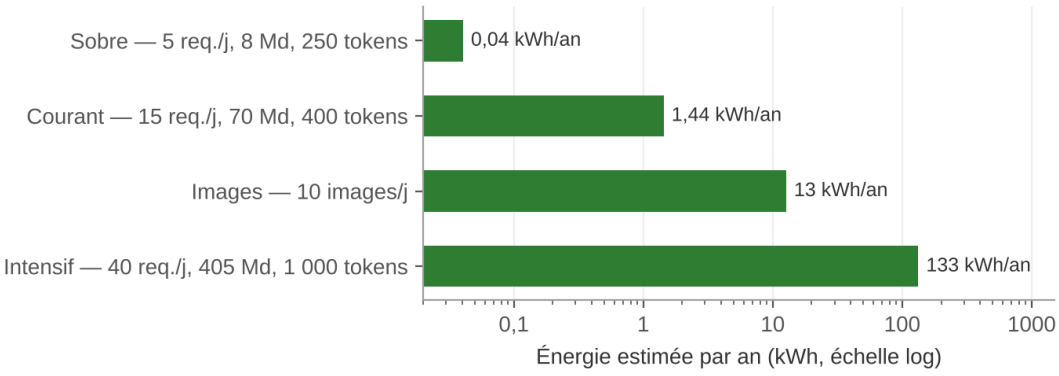


Fig. 9 — Énergie annuelle estimée de quatre scénarios (échelle logarithmique).

L'écart entre un usage sobre et un usage intensif atteint un facteur supérieur à 3 000. Le choix du modèle et la longueur des réponses pèsent davantage que le nombre de requêtes.

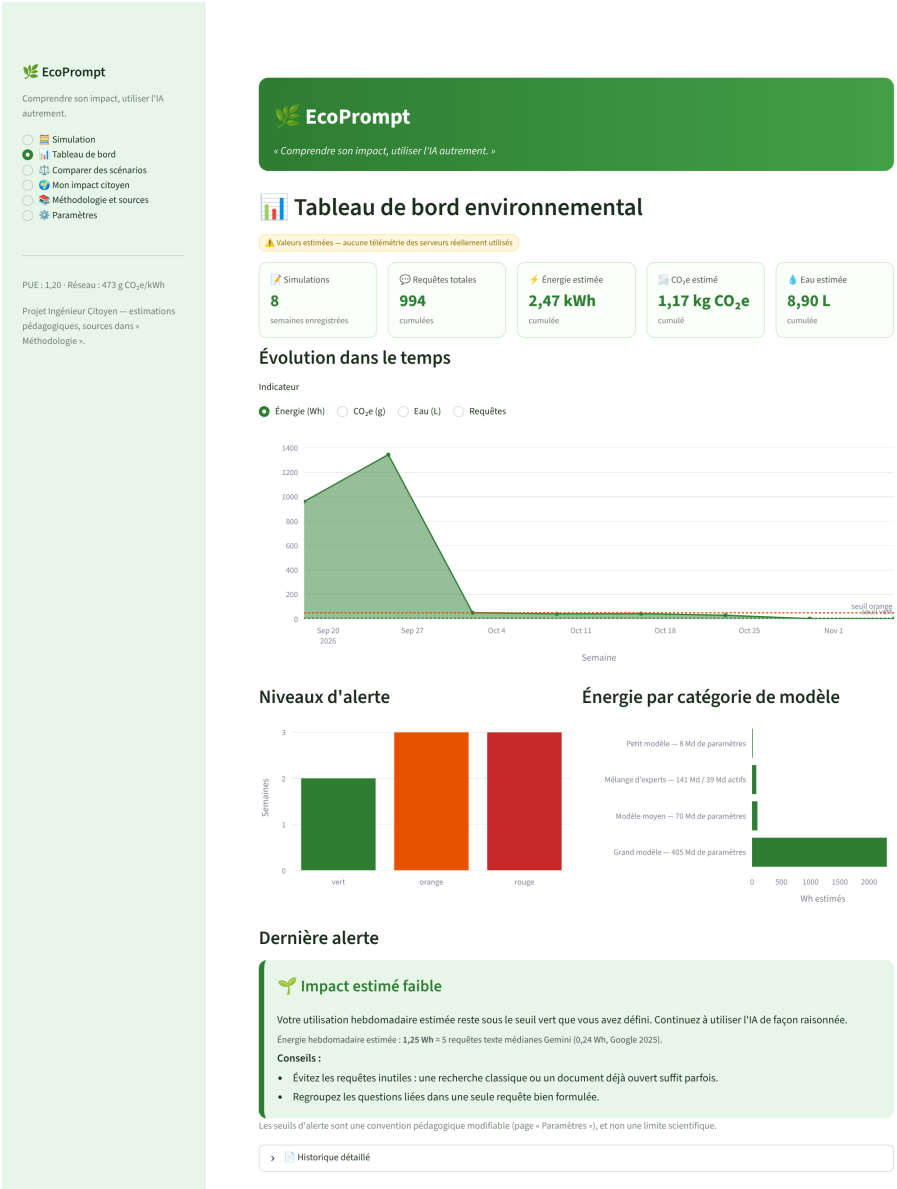


Fig. 7 — Tableau de bord environnemental (historique de démonstration fictif de 8 semaines).

13.2 Validation par comparaison avec des valeurs publiées

Aucune mesure physique n'a été réalisée dans ce projet. La validation consiste à vérifier que les estimations d'EcoPrompt sont du même ordre de grandeur que des valeurs publiées indépendantes, en gardant à l'esprit que les conditions ne sont pas identiques.

Comparaison	EcoPrompt (estimé)	Valeur publiée	Remarque
Petit modèle (8 Md), 400 tokens	0,036 Wh	0,047 Wh — texte, ≤ 11 Md [3]	Même ordre de grandeur ; longueur des réponses non contrôlée dans [3]
Modèle 70 Md, 400 tokens	0,263 Wh	0,24 Wh — médiane Gemini [2]	Même ordre de grandeur ; modèle et tokens de Gemini non publiés
Eau, 0,24 Wh avec WUE Google	0,253 mL	0,26 mL [2]	Écart ≈ 3 % : implémentation cohérente
CO_2e, 70 Md, 400 tokens	0,124 g	0,03 g [2] ; 1,14 g [7]	Encadré par deux périmètres différents (market-based / ACV)

Tableau 14 — Confrontation des estimations aux valeurs publiées.

13.3 Protocole de validation expérimentale proposé

Pour aller plus loin, un protocole de mesure peut être conduit avec du matériel accessible : (1) exécuter localement un petit modèle ouvert ; (2) mesurer l'énergie avec CodeCarbon (logiciel déjà utilisé dans [3] et [6]) ou un wattmètre sur prise ; (3) générer des réponses de 100, 400 et 1 000 tokens, répétées au moins dix fois ; (4) comparer la pente énergie/token mesurée à la prédiction d'EcoPrompt. Ce protocole n'a pas encore été réalisé : il constitue la première perspective du projet (section 16).

14. IMPACT SOCIAL ET SENSIBILISATION CITOYENNE

La page « Mon impact citoyen » permet de simuler des changements d'habitudes et d'en observer l'effet à l'échelle d'un groupe (classe, promotion, association).

Exemple (**estimé**) : en partant du scénario « courant », éviter ou regrouper 30 % des requêtes et raccourcir les réponses de 25 % réduit l'énergie annuelle estimée de 50 %. Si l'on utilise en plus un modèle de 8 Md, la réduction estimée atteint 93 %. Pour une classe de 30 personnes, cela représente environ 40,2 kWh et 19,0 kg CO_2e évités par an selon les hypothèses par défaut.

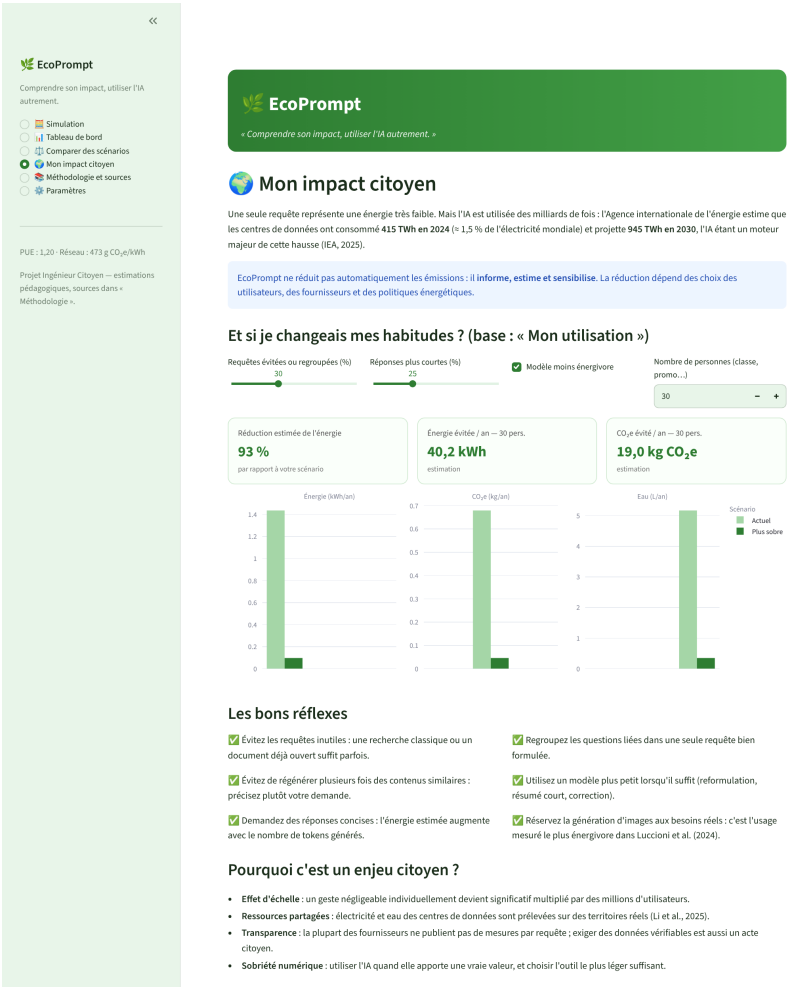


Fig. 10 — Page « Mon impact citoyen ».

Positionnement. EcoPrompt ne réduit pas automatiquement les émissions : sa fonction est d'**informer, estimer et sensibiliser**. Une réduction réelle dépend des choix des utilisateurs, mais aussi des fournisseurs (efficacité des modèles, énergie bas-carbone) et des politiques publiques. Un risque d'effet rebond existe : une IA perçue comme « peu coûteuse » peut être davantage utilisée.

La dimension citoyenne du projet repose sur quatre idées : l'**effet d'échelle** (un geste négligeable individuellement devient significatif collectivement) ; les **ressources partagées** (électricité et eau prélevées sur des territoires réels) ; la **transparence** (exiger des données vérifiables des fournisseurs) ; la **sobriété numérique** (utiliser l'IA quand elle apporte une vraie valeur, avec l'outil le plus léger suffisant).

15. LIMITES SCIENTIFIQUES ET TECHNIQUES

- **Absence de télémétrie** : EcoPrompt n'a accès à aucune mesure des serveurs réellement utilisés. Il estime l'impact d'un usage déclaré, pas d'une requête individuelle réelle.
- **Modèle simplifié** : EcoLogits suppose des GPU H100, un lot de 64 requêtes, et ne modélise ni le réseau, ni le stockage, ni les machines inactives [1]. La latence utilise une formule de repli que la documentation annonce comme amenée à être remplacée.

- **Taille des modèles commerciaux inconnue** : le rattachement d'un service à un profil de taille est une hypothèse.
- **Tokens d'entrée** non pris en compte par la méthode de référence.
- **Localisation et heure** inconnues : l'intensité carbone varie d'un facteur supérieur à 20 entre la France et la moyenne mondiale ; elle varie aussi selon l'heure.
- **Périmètres hétérogènes** : les valeurs publiées pour l'eau varient d'un facteur ≈ 170 selon qu'elles incluent ou non l'électricité et la fabrication (tableau 11).
- **Valeurs fournisseurs non auditées** : la mesure de Google [2] est une auto-déclaration ; l'ACV de Mistral [7] se présente comme une « première approximation ».
- **Hors périmètre** : terminal de l'utilisateur, fabrication (sauf valeurs ACV citées), entraînement (présenté séparément), effets rebond.
- **Seuils d'alerte** conventionnels, non scientifiques.
- **Données déclaratives** : l'utilisateur estime lui-même son nombre de requêtes et de tokens.

16. PERSPECTIVES D'AMÉLIORATION

- Réaliser le protocole de mesure locale avec CodeCarbon (section 13.3) et publier les résultats dans le dépôt.
- Développer une extension de navigateur comptant automatiquement les requêtes et la longueur des réponses, sans transmettre leur contenu.
- Intégrer l'intensité carbone horaire (par exemple les données éCO2mix de RTE) et la localisation probable des centres de données.
- Ajouter les impacts de fabrication (carbone intrinsèque) lorsque des données fiables par requête seront disponibles.
- Mettre à jour automatiquement les coefficients à chaque nouvelle version d'EcoLogits.
- S'aligner sur les référentiels émergents, comme la méthodologie AFNOR Frugal AI utilisée par Mistral AI [7].
- Proposer une version anglaise et espagnole, et un mode « atelier » pour les classes.

17. CONCLUSION

Le projet EcoPrompt répond à la problématique en rendant visible un impact habituellement invisible. L'application estime l'énergie, les émissions de CO_2e et l'eau associées à un usage de l'IA à partir d'une méthode publiée, avec des paramètres sourcés et modifiables ; elle les traduit en indicateurs, en graphiques et en alertes compréhensibles ; elle propose des gestes concrets et en montre l'effet à l'échelle d'un groupe.

Les principaux enseignements sont que **la taille du modèle et la longueur des réponses comptent davantage que le nombre de requêtes**, que **la localisation des serveurs peut changer le bilan carbone d'un facteur supérieur à 20**, et que **les données publiques restent rares et hétérogènes**. L'application est fonctionnelle, testée (59 tests réussis), exécutable localement sans service payant et documentée pour être publiée sur GitHub.

L'objectif du projet est atteint dans son périmètre : EcoPrompt n'est pas un instrument de mesure, mais un outil d'estimation honnête et de sensibilisation, qui invite chacun à « comprendre son impact, et utiliser l'IA autrement ».

18. BIBLIOGRAPHIE ET SOURCES SCIENTIFIQUES

Sources consultées et vérifiées le 6 novembre 2026.

[1] Rincé, S. & Banse, A. (2025). EcoLogits: Evaluating the Environmental Impacts of Generative AI. Journal of Open Source Software, 10(111), 7471. DOI : 10.21105/joss.07471. *Méthode d'estimation open source (régression sur mesures ML.ENERGY / LLM-Perf)*, 2025 (page consultée le 06/11/2026). https://ecologits.ai/latest/methodology/llm_inference/

[2] Elsworth, C. et al. (2025). Measuring the environmental impact of delivering AI at Google Scale. arXiv:2508.15734. *Télémétrie de production publiée par le fournisseur (non auditée par un tiers)*, 21/08/2025 (données de mai 2025). https://arxiv.org/abs/2508.15734

[3] Luccioni, A. S., Jernite, Y. & Strubell, E. (2024). Power Hungry Processing: Watts Driving the Cost of AI Deployment? ACM FAccT 2024. arXiv:2311.16863. *Mesure expérimentale (CodeCarbon, nœud 8×A100-80GB, AWS)*, 2024. https://arxiv.org/abs/2311.16863

[4] Li, P., Yang, J., Islam, M. A. & Ren, S. (2025). Making AI Less 'Thirsty': Uncovering and Addressing the Secret Water Footprint of AI Models. Communications of the ACM (accepté). arXiv:2304.03271v5. *Modèle d'estimation (WUE sur site + intensité hydrique de l'électricité)*, v5 du 26/03/2025. https://arxiv.org/abs/2304.03271

[5] Patterson, D. et al. (2021). Carbon Emissions and Large Neural Network Training. arXiv:2104.10350. *Estimation (données partielles fournies par OpenAI + moyenne réseau US)*, 2021. https://arxiv.org/abs/2104.10350

[6] Luccioni, A. S., Viguier, S. & Ligozat, A.-L. (2023). Estimating the Carbon Footprint of BLOOM, a 176B Parameter Language Model. JMLR 24(253). arXiv:2211.02001. *Mesure (énergie de calcul) + estimation (fabrication, inactivité)*, 2022–2023. https://arxiv.org/abs/2211.02001

[7] Mistral AI, Carbone 4, ADEME (2025). Our contribution to a global environmental standard for AI (ACV de Mistral Large 2, méthodologie AFNOR Frugal AI, revue par Resilio et Hubblo). *Analyse de cycle de vie (ISO 14040/44), « première approximation »*, 22/07/2025. https://mistral.ai/news/our-contribution-to-a-global-environmental-standard-for-ai

[8] Agence internationale de l'énergie (2025). Energy and AI. Chiffres repris par Scientific American, 10/04/2025. *Rapport d'organisme public (estimation et projection)*, 10/04/2025. https://www.iea.org/reports/energy-and-ai

[9] Ember (2025). Global Electricity Review 2025, chap. 3.3. *Statistique (intensité des émissions de la production électrique)*, 08/04/2025 (données 2024). https://ember-energy.org/latest-insights/global-electricity-review-2025/

[10] RTE (2025). Bilan électrique 2024 — Émissions. *Statistique officielle du gestionnaire de réseau français*, 2025 (données 2024). https://analysesetdonnees.rte-france.com/bilan-electrique-2024/emissions

[11] Our World in Data, d'après Ember (2026) et Energy Institute (2026). Carbon intensity of electricity. *Statistique agrégée (cycle de vie)*, mise à jour du 30/06/2026 (données 2024). https://ourworldindata.org/grapher/carbon-intensity-electricity

[12] Meta AI (2024). Introducing Llama 3.1 (modèles 8B, 70B, 405B). *Documentation technique du modèle*, 23/07/2024. https://ai.meta.com/blog/meta-llama-3-1/

[13] Mistral AI (2024). Cheaper, Better, Faster, Stronger — Mixtral 8x22B (141 Md de paramètres, 39 Md actifs). *Documentation technique du modèle*, 17/04/2024. https://mistral.ai/news/mixtral-8x22b

Note : la page web de l'IEA n'étant pas accessible lors de la vérification, les chiffres de [8] ont été contrôlés via leur reprise par *Scientific American* (10 avril 2025).

Annexe — Galerie de l'application

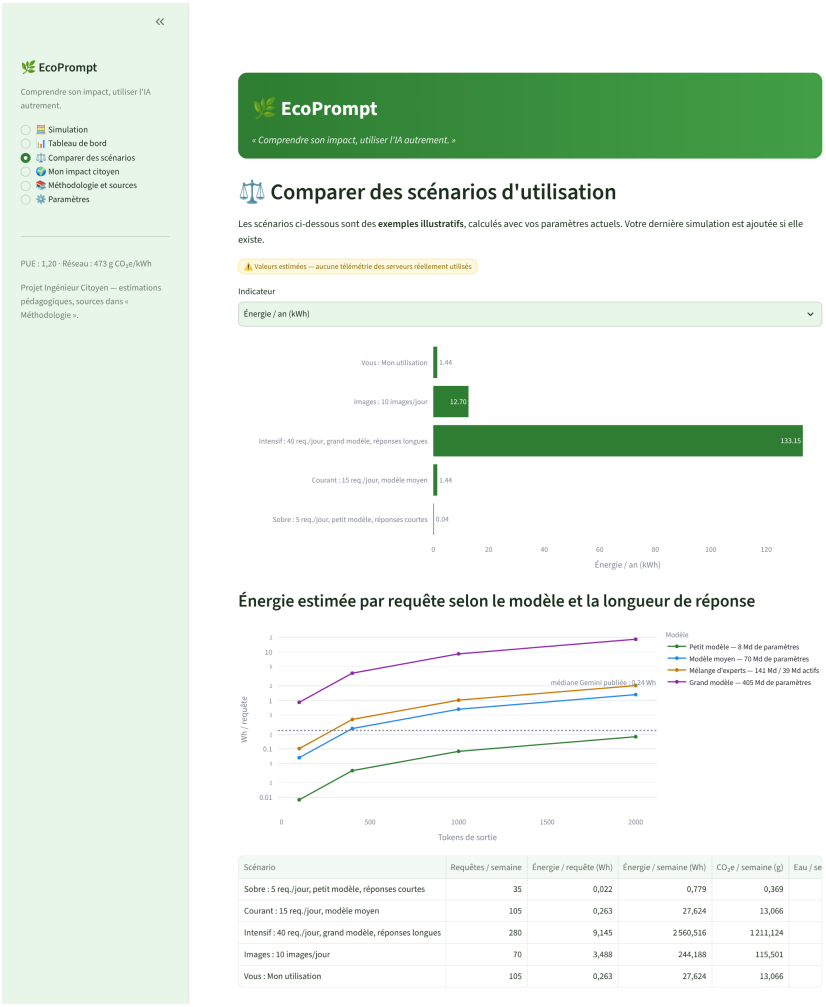


Fig. 8 — Page « Comparer des scénarios ».

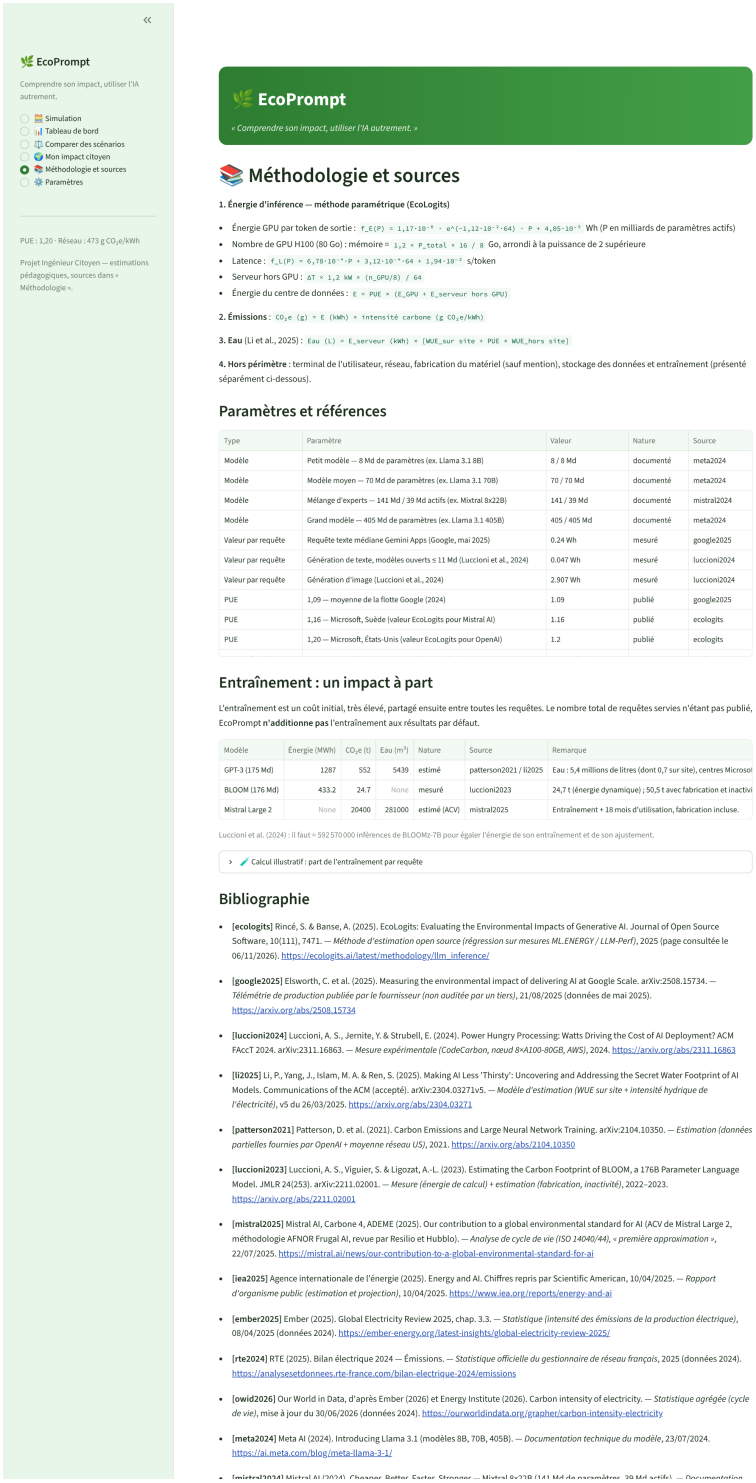


Fig. 11 — Page « Méthodologie et sources ».